问数 AskData

基于自然语言交互的数据分析平台

AI WEB 网页开发挑战赛 · 赛道二 · 技术文档

学　　校：**广东科贸职业学院**

指导老师：**林龙键**

团队成员：**罗勇添、辛嘉炜、林俊宁**

提交日期：**2026 年 11 月**

本作品由项目组独立完成 · 截图与数据均来自系统真实运行结果

目 录

摘要

一、背景与痛点：我们要解决的方向

二、目标用户与典型场景

三、方案总览与创新点

四、系统架构

五、数据接入与元数据

六、核心实现一：Text-to-SQL 流水线

七、核心实现二：图表推荐与创意可视化

八、核心实现三：文档、截图数据化与 RAG

九、工程化与稳定性

十、测试与评测

十一、部署与运行

十二、局限与演进规划

十三、团队分工

附录 A：NL2SQL Prompt（节选）

附录 B：主要 API

摘要

问数 AskData 是一个面向业务人员的对话式数据分析平台。用户上传 CSV / Excel / PDF / Word / 图片后，用一句中文提问，系统自动完成 **自然语言转 SQL（NL2SQL）→ 查询执行 → 按数据类型推荐图表 → 智能洞察 → 多轮追问**；同时支持把 PDF 财报、Word 报告、图片截图中的表格提取为可分析数据集，并对文档正文进行带引用的 RAG 问答。

针对“业务同学不会写 SQL、取数排队、数据散落在非结构化文件里”三类现实问题，本作品把“从数据到结论”的链路压缩成一次对话，并保证每个结论都能展开 SQL 与引用片段核对。

在可视化层，本作品做了两项重点增强：

1. **按数据类型自动推荐图表**：时间趋势、分类对比、占比、两个分类维度的矩阵、两个连续数值的相关性、品类构成等分别推荐折线 / 柱状 / 环形 / 热力图 / 散点图 / 树图 / 自研商品图；推荐图表排在第一位并说明理由，用户仍可自由切换。

2. **商品图创意可视化**：以灰色商品图形为底，颜色只在图形内部按占比从下往上填充，配合中心向外扩散的羽化入场动画、悬停放大与点击下钻，让“品类构成”这类数据不再只是普通柱状图。

实测结果：36,000 行双 11 数据上 6 类典型问题全部生成正确 SQL 与图表，单问耗时 8–12 秒；多轮追问可继承上下文；模糊问题主动澄清；SQL 报错可自动修复；PDF / Word / 图片表格均能解析并完成带引用问答。全新机器安装考官包约 2 分钟即可运行；最终演示视频 6 分 06 秒。

一、背景与痛点：我们要解决的方向

1.1 工具门槛：会查数据的人太少

企业里真正会写 SQL 的人集中在数据团队，而需要看数据的人遍布运营、市场、销售、财务。一次取数需要“提需求 → 排队 → 等报表”，周期常常以天计，业务决策被迫滞后。

1.2 流程门槛：分析链路被切断

传统 BI 工具要求用户先理解维度、度量、聚合、过滤等概念，再拖拽配置图表。业务人员往往“知道自己想问什么”，却不知道怎么把它翻译成工具操作，分析链路在第一步就中断。

1.3 数据形态门槛：大量数据不在数据库里

企业里很多关键数据并不在规整的 Excel 或数据库里，而是躺在 **PDF 财报、Word 报告、聊天截图**中。传统工具无法读取这些内容，导致“看得见、分析不了”。

1.4 可视化门槛：有图不等于看得懂

即使生成了图表，也常见两类问题：一是图表类型选错（时间趋势画成柱状、品类构成画成散点）；二是图表“信息密度低、不够直观”，业务人员仍需要在图和表之间来回对照。本项目把“选什么图、怎么把图做得更贴近业务语义”作为独立一层来解决。

1.5 方向判断

因此，本项目要解决的不是“再做一个 BI 图表工具”，而是：

> ***让任何人都能用自然语言直接获得可信、可追溯的数据结论，把散落在文档与图片里的数据变成可分析资产，并让图表本身更接近业务语义。***

二、目标用户与典型场景

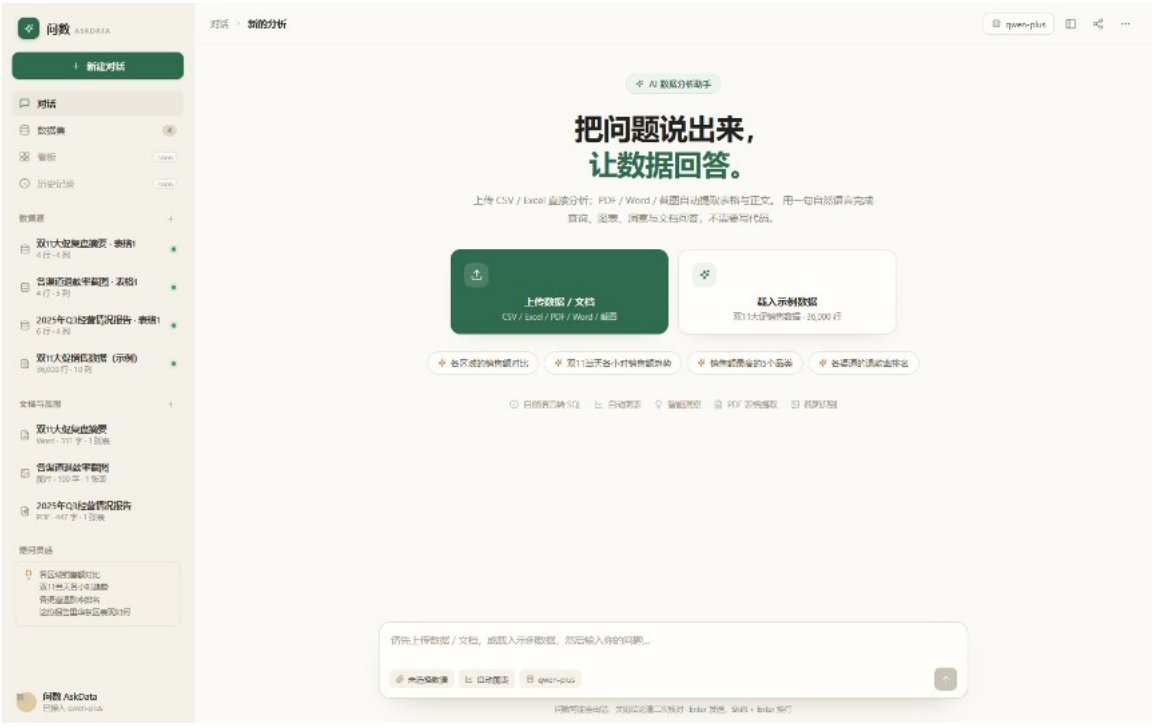
用户	痛点	使用方式
运营 / 市场人员	不会 SQL，取数依赖分析师	上传活动数据，直接问“各渠道退款率排名”
数据分析师	重复取数占用大量时间	用对话快速出初版 SQL 与图表，再在检查器中核对
管理者 / 财务	看 PDF 财报，无法快速定位数字	上传财报，问“华东区 Q3 销售额和同比”
学生 / 研究者	数据在 Excel、截图里	上传文件即分析，无需搭环境

典型场景：大促复盘、月度经营分析、财报关键指标提取、运营异常归因、课程作业数据分析。

三、方案总览与创新点

3.1 产品形态

左侧为数据源与文档列表，中间为对话流，右侧为检查器（结果表 / SQL / 字段结构）。所有分析结果以“卡片”形式呈现：推荐图表、KPI 概览、洞察、SQL、追问建议。



产品欢迎页

3.2 核心能力

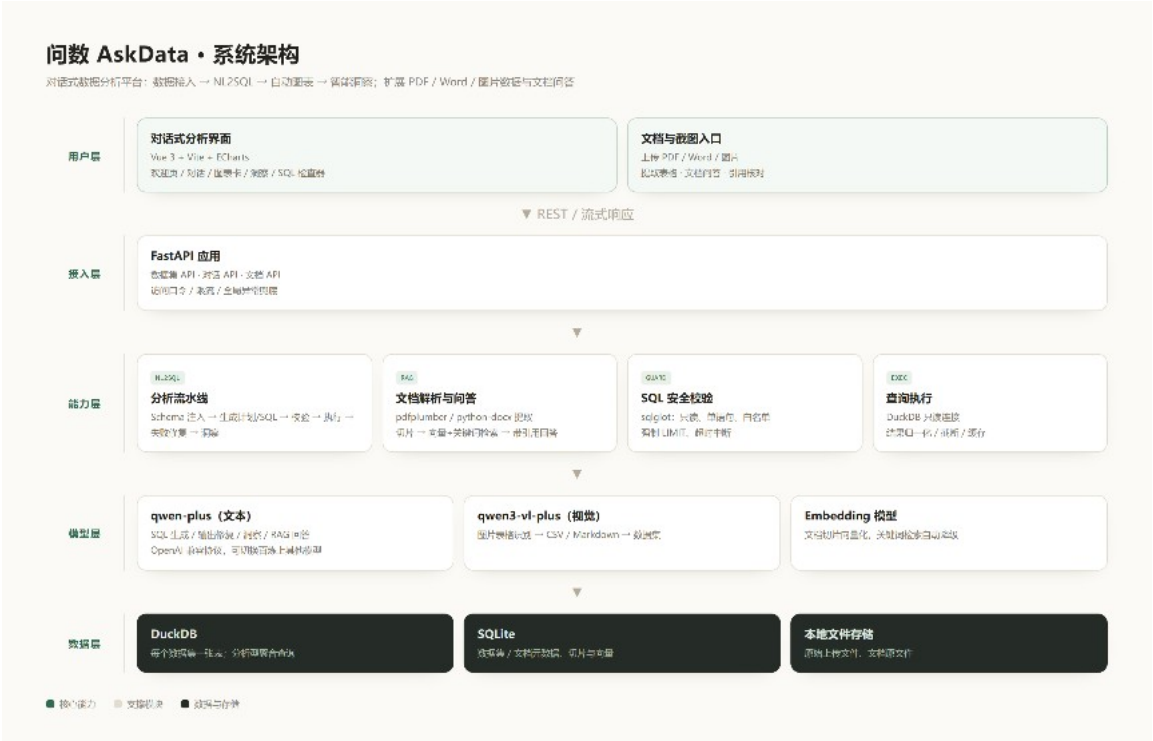
- **对话即分析**：一句话完成查询、图表、结论，结果自带可展开 SQL；
- **非结构化数据平权**：PDF / Word / 图片 → 自动提取表格为数据集，复用同一套分析链路；
- **按数据类型自动选图**：识别时间、分类、占比、矩阵、相关性等数据结构，推荐合适的图表；
- **商品图创意可视化**：灰色商品图形做底、颜色在图像内部按占比填充，并带入场动画与下钻；
- **可追溯的 AI**：SQL 可核对、文档回答带引用，降低“AI 胡说”的风险；
- **演示级鲁棒性**：SQL 校验与失败重试、模型超时降级、演示模式、数据源重置与会话保留。

3.3 与常见方案的区别

环节	常见做法	本作品做法
Text-to-SQL	直接让大模型写 SQL	先出分析计划，再生成 SQL，并经静态校验与失败重试
图表生成	让模型直接写 ECharts 配置	输出中间层 chart spec；前端按数据画像推荐图表并统一渲染
图表选择	固定柱/线/饼	自动推荐 + 推荐理由 + 用户可切换，覆盖商品图、热力、树图、散点
结论生成	SQL 与结论一次生成	二次调用，强制引用真实查询数字
数据接入	仅 CSV / Excel	CSV / Excel / PDF / Word / 图片
数据状态	切走即丢、只能重传	数据源会话缓存 + 一键“重置数据源”重新读取原文件

可信度	黑盒回答	SQL 检查器 + 文档引用片段

四、系统架构



系统架构

系统分为五层：

- **用户层**：Vue 3 + Vite + ECharts 单页应用，负责对话、图表、检查器、文档问答与图表切换；
- **接入层**：FastAPI 提供数据集、对话、文档三类 API，带访问口令与限流；生产模式同时托管前端静态资源；
- **能力层**：NL2SQL 流水线、SQL 安全校验、DuckDB 执行、图表推荐、洞察生成、文档解析与 RAG；
- **模型层**：通过 OpenAI 兼容协议接入阿里云百炼的 qwen-plus（文本）、qwen3-vl-plus（视觉）与 Embedding 模型，可切换其他模型；
- **数据层**：DuckDB 存分析数据，SQLite 存元数据，本地文件存原始上传文件。

五、数据接入与元数据

5.1 数据支持

- CSV / Excel（xlsx）：自动编码探测（UTF-8 / GBK）、中文表头、类型推断（时间、数值、布尔）、空值与重复提示；
- PDF / Word：提取正文与表格；
- 图片：调用视觉大模型识别表格，输出 CSV / Markdown 后转为 DataFrame。

5.2 写入 DuckDB

解析后的 DataFrame 直接注册为 DuckDB 表，每个数据集独立一个 `.duckdb` 文件。选择 DuckDB 的原因：

- 分析型聚合性能好，单机零部署；
- 支持直接读取 CSV，方便扩展；
- 只读连接即可完成安全隔离。

5.3 给模型看的 Schema

系统会把每个字段的 **类型、样例值、枚举值、空值率、取值范围** 注入 Prompt。这是 SQL 准确率的关键：模型必须知道“数据长什么样”，才能写出正确的字段名与过滤条件。

```
表名：demo_double11（行数：36,000，列数：10）
- order_time  TIMESTAMP  范围 2025-10-01 00:05:28 ~ 2025-11-12 23:59:33
- region      VARCHAR    枚举=华东/华南/华北/西南/东北/华中
- amount      DOUBLE     范围 33.26 ~ 19800
```

5.4 数据源状态管理

- 每个数据源 / 文档的对话保存在前端会话缓存中，切换出去再点回来不会清空；
- 点“新建对话”才清空当前数据源的会话；
- 顶栏“重置数据源”会重新读取原始文件、重建 DuckDB 表，并清空当前数据源会话，避免误用旧数据；
- 重置接口支持示例数据与上传的 CSV / Excel；文档派生数据集提示重新导入。

六、核心实现一：Text-to-SQL 流水线

6.1 总体流程

```
用户问题
  → Schema / 口径 / 历史上下文注入
  → 大模型输出 JSON（intent + plan + sql + chart + assumptions）
  → sqlglot 静态校验（只读、单语句、表白名单、强制 LIMIT）
  → DuckDB 执行
  → 失败则把报错回喂模型修复（最多 2 次）
  → 洞察二次调用（结论 + 依据 + 追问建议）
  → 前端推荐图表并渲染
```

6.2 为什么不用 LangChain

比赛周期短，LangChain 的抽象层会增加调试成本。我们选择显式 pipeline：

- 每一步都可独立打日志、定位问题；
- 便于在技术文档中清晰说明“我们做了什么”；
- 不依赖框架版本，部署更轻。

6.3 SQL 安全校验

大模型可能生成危险或越权 SQL，因此执行前必须过一层 `sqlglot` 静态校验：

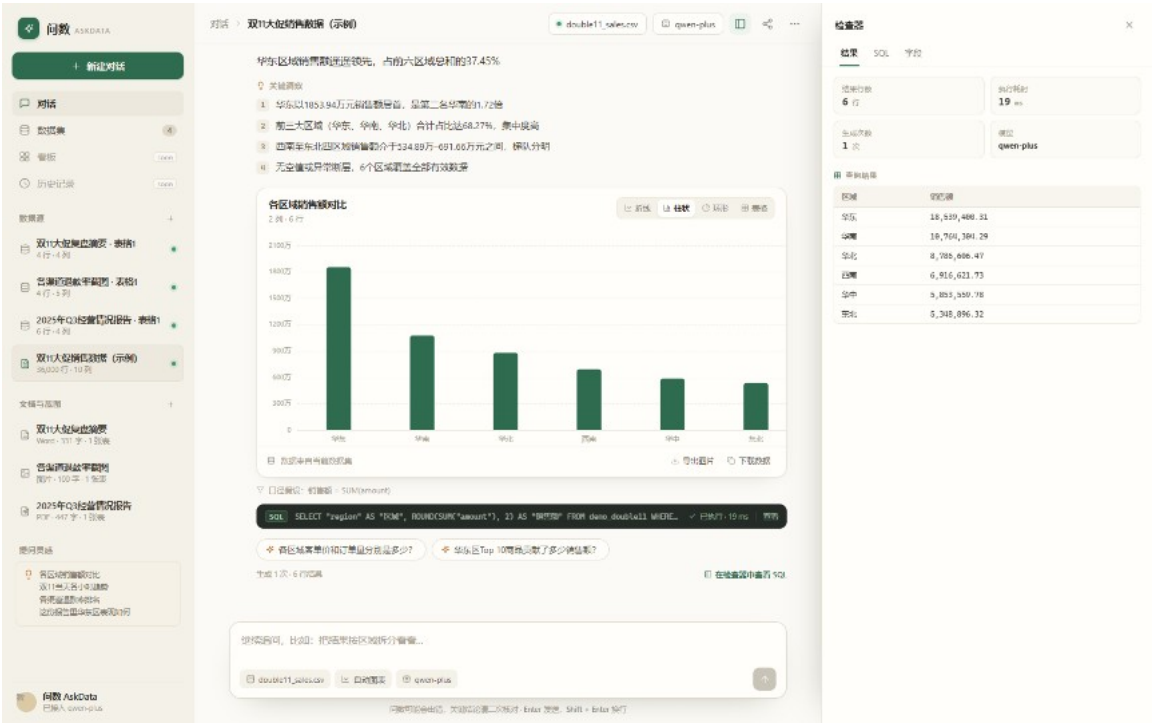
- 只允许单条 `SELECT / WITH`；
- 禁止 `INSERT / UPDATE / DELETE / DROP / ATTACH` 等；
- 表名白名单（仅当前数据集）；
- 强制追加 `LIMIT`；
- 只读 DuckDB 连接 + 查询超时中断。

6.4 失败自动修复

真实场景中 SQL 错误大多来自字段名、方言函数、类型不匹配。系统会把数据库原始报错回喂模型：

```
上一条 SQL 执行失败。
错误信息：Binder Error: Referenced column "region_name" not found
原 SQL：...
请修复后只输出 JSON。
```

实测中，复杂问题在第一次失败后可自动修复成功，显著提升端到端成功率。



检查器：结果表与 SQL 可核对

6.5 时间口径：以数据为准

Demo 数据是 2025 年，而系统日期是 2026 年。如果直接用 `CURRENT_DATE`，“上个月”“最近 30 天”“双 11 当天”都会查空。为此我们：

- 在 Schema 中注入每个时间字段的真实 min/max；
- 把 Prompt 中的相对时间改为以 `MAX(时间字段)` 为基准；
- 明确要求“根据数据时间范围推断年份”。

6.6 输出容错

大模型偶尔会把数组写成字符串、把 `null` 写成空串。后端增加归一化层，并在修复路径加异常兜底，避免一个 500 毁掉整个演示。

七、核心实现二：图表推荐与创意可视化

7.1 为什么需要“按数据类型自动选图”

同一个结果集可以画成多种图，但只有少数是正确的：

- 时间趋势用柱状会遮住变化趋势；
- 品类构成用散点几乎不可读；
- 两个分类维度 + 一个指标用单柱状图会丢失矩阵关系；

- 低离散值的“数量”字段画散点会变成几条水平线。

因此前端在渲染前先做**数据画像 + 意图判断**，再决定默认图表。

7.2 推荐器规则

数据特征 / 意图	推荐图表	理由
存在时间字段	折线图	趋势变化最直观
数据点 > 12 且单指标	折线图	点太多柱状图会拥挤
两个分类维度 + 一个数值	热力图	矩阵关系一眼可见
两个连续数值字段	散点图	看相关性与离群点
品类 / 商品构成（4–12 类）	**商品图**	图像化占比，更有业务画面感
占比 / 份额 / 构成	环形图	部分与整体关系
分类对比（≤12 类）	柱状图	横向比较最清晰
多指标对比	分组柱状图	同维度多指标并列
字段复杂 / 不适合图形化	数据明细	避免错误图表

实现要点：

- 推荐类型**排在切换栏第一位并标注“推荐”**，同时显示推荐理由；
- 其他图表列在后面，用户可自由切换；
- 表格不再占顶部切换位置，收进底部“数据明细”按钮；
- 散点图额外检查数值字段离散程度，避免低离散值造成的“几条水平线”；
- 热力图对同一单元格的多条记录先聚合去重，关闭热力动画并开启标签防重叠。

7.3 支持的图表类型

类型	适用场景	视觉增强
柱状	分类对比、排名	渐变圆角、数值标签、均值线
折线	时间趋势	面积渐变、平滑曲线、均值虚线
环形	占比构成	中心合计、分类色板、百分比标签
商品图	品类构成	灰度商品图形、内部占比填充、入场动画、点击下钻
热力	两个分类维度矩阵	色阶、单元格聚合、标签防重叠
树图	层级占比	面积映射、百分比标签
散点	两个连续数值	相关性、悬停详情
数据明细	复杂字段	表头吸顶、单元格数据条、Zebra 行

7.4 商品图创意可视化

这是本项目在“可视化表达”上的重点创新：不是把数字塞进普通图表，而是让**商品图形本身成为数据载体**。

- 每个品类对应一张**统一风格的商品图形**（手机、沙发、连衣裙、口红、苹果等，Canvas 自绘，不依赖系统 emoji）；
- 商品图形整体渲染为**灰色**作为底；
- 该品类的销售额占比用**浅色**从图形内部底部向上填充，颜色只出现在商品轮廓内部；
- 不同品类不同颜色，颜色低饱和，避免抢走商品本体的注意力；
- 品类名称居中显示在商品图形下方，百分比显示在图形上方；
- 每行最多 4 个，超出按左→右、上→下换行，窄屏自动降为 3 / 2 列；
- 无购物袋、无边框，商品图形就是主体；
- **入场动画**：从中心向外扩散、羽化边缘、透明到不透明，逐项错峰；
- **交互**：悬停放大，点击自动把“查看某品类销售明细”填入输入框，作为下钻入口；
- 百分比数字随填充从 0 涨到实际值。



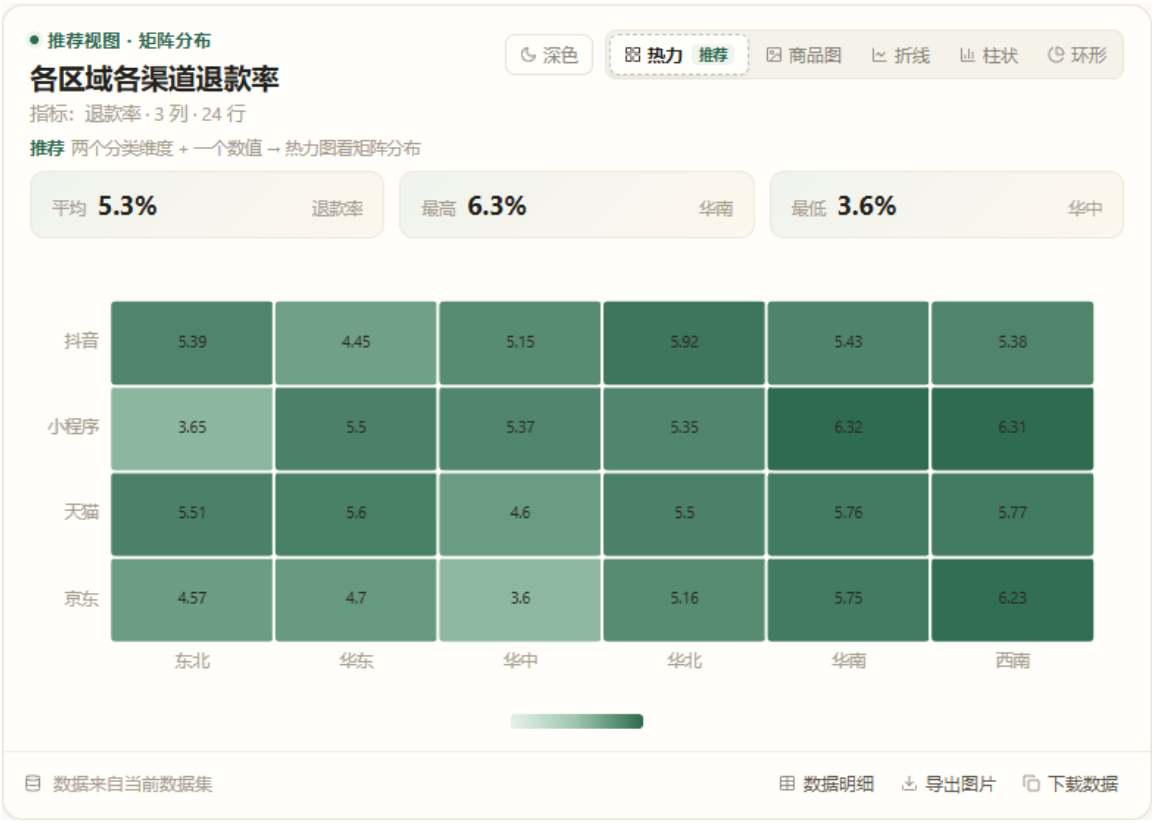
商品图创意可视化

7.5 图表的可读性与一致性

- 顶部自动生成 KPI 概览：合计 / 最高 / 平均；比率类指标改为平均 / 最高 / 最低；
- 图表标题、指标说明、推荐理由、图表类型切换集中在卡片头部；
- 支持浅色 / 深色两套主题；
- 图表导出图片时自动带上标题、指标说明与品牌水印；
- 所有数值统一万 / 亿 / 百分比格式，避免“12345678.9”这种难以阅读的数字。



推荐柱状图


推荐视图 · 矩阵分布
各区域各渠道退款率
指标：退款率 · 3 列 · 24 行
推荐 两个分类维度 + 一个数值 → 热力图看矩阵分布
深色
热力 推荐
商品图
折线
柱状
环形
平均 5.3% 退款率
最高 6.3% 华南
最低 3.6% 华中
抖音 5.39 4.45 5.15 5.92 5.43 5.38
小程序 3.65 5.5 5.37 5.35 6.32 6.31
天猫 5.51 5.6 4.6 5.5 5.76 5.77
京东 4.57 4.7 3.6 5.16 5.75 6.23
东北 华东 华中 华北 华南 西南
数据来自当前数据集
数据明细
导出图片
下载数据

热力图


探索视图 · 层级占比
各品类销售额占比
指标：销售额占比 · 2 列 · 5 行
推荐 品类构成 → 商品图展示更有画面感
深色
商品图 推荐
树图
折线
柱状
环形
合计 100% 销售额占比
最高 69.6% 3C数码
平均 20.0% 最低 2.2%
3C数码
69.6%
家居
11.1%
女装
9.4%
美妆
7.7%
食品
2.2%
数据来自当前数据集
数据明细
导出图片
下载数据

树图

7.6 智能洞察

查询成功后，系统二次调用模型，输入是“问题 + SQL + 结果摘要”，要求输出：

- headline：一句话结论；
- bullets：2–4 条带真实数字的依据；
- followups：2 条自然的追问建议。

Prompt 中强制约束：**禁止编造结果中不存在的数字**，金额自动换算万 / 亿，比率保留两位小数。

示例（真实运行结果）：

> *双11 当日销售额呈双峰分布，0 点峰值达 147.90 万元。*
>
> *- 0 点销售额达 147.90 万，为全天最高，是最低值（5 点 3.14 万）的 47.1 倍；*
>
> *- 20 点出现第二高峰 48.45 万，较19 点增长 14.17%；*
>
> *- 凌晨 3–5 点持续低迷，三小时合计仅 14.50 万，占全天不足 1.2%。*



小时趋势分析

八、核心实现三：文档、截图数据化与 RAG

8.1 表格提取

类型	解析方式	结果
PDF	pdfplumber 提取文字与表格	表格 → DataFrame → DuckDB 数据

		集
Word	python-docx 提取段落与表格	表格 → DataFrame → DuckDB 数据集
图片	qwen3-vl-plus 视觉模型识别	CSV / Markdown → DataFrame → DuckDB 数据集
扫描版 PDF	渲染页面 → 视觉模型 OCR	文字 + 表格

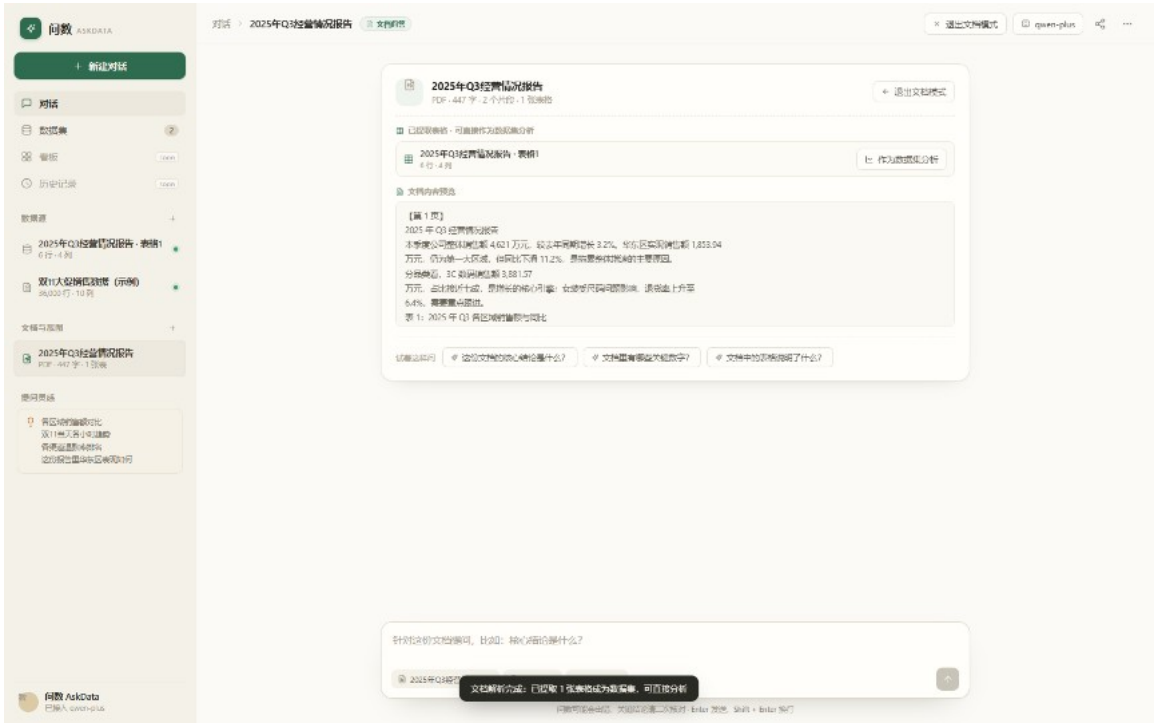
关键架构决策：所有来源的表格最终都转成 DataFrame 并注册为数据集，直接复用已有的 NL2SQL、图表、洞察、检查器能力，不需要为文档另写一套分析链路。

8.2 文档 RAG

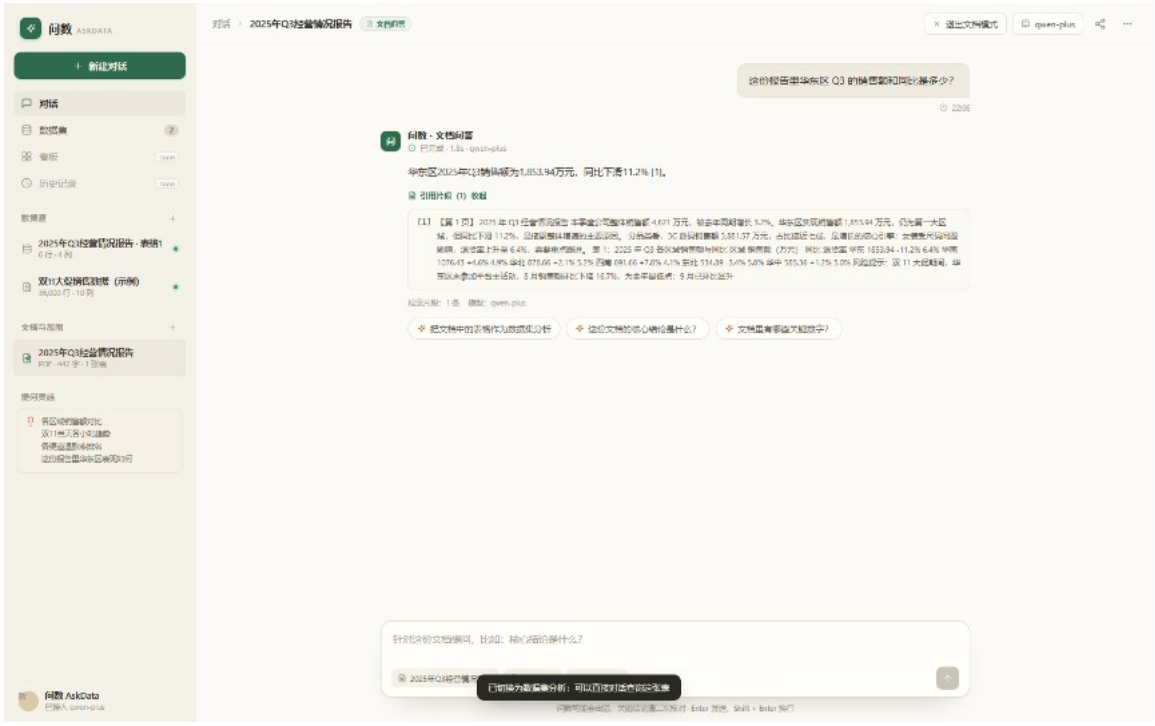
正文按 420 字、80 字重叠切片；上传时调用 Embedding 模型生成向量并存储；提问时用“向量相似度 + 字符 bigram 关键词”混合检索 Top-5 片段，再由大模型生成带引用编号的回答。向量接口不可用时自动降级为关键词检索。

8.3 实测效果

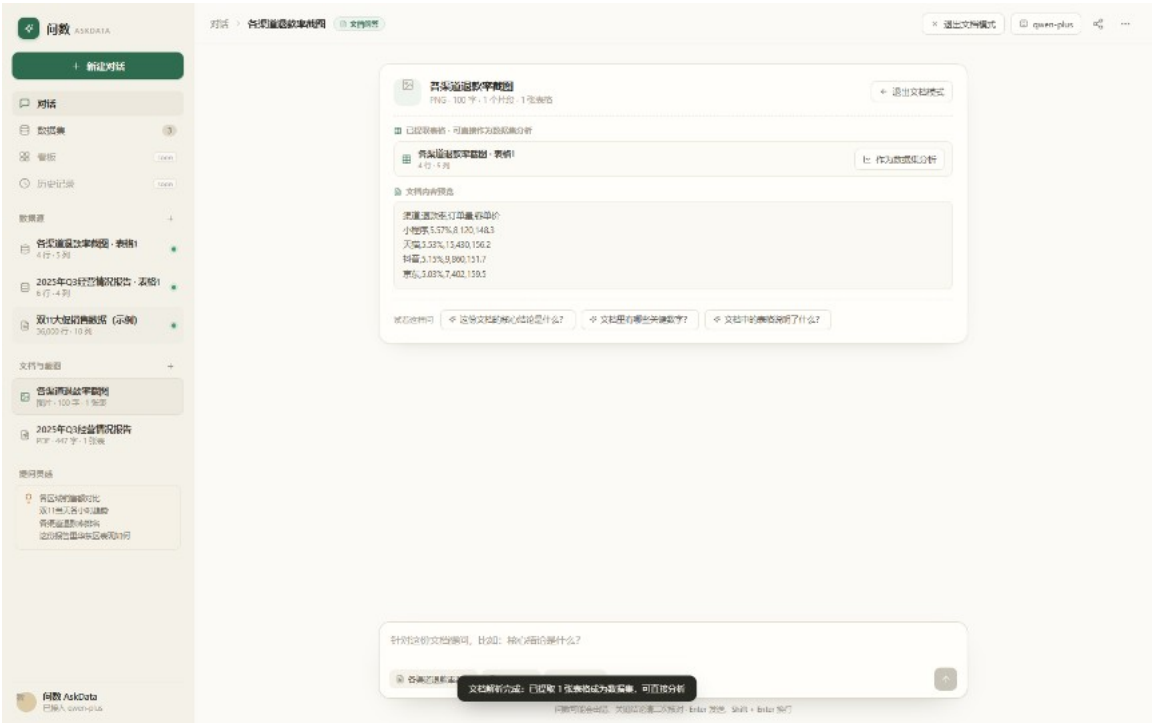
文件	解析结果	问答
2025 年 Q3 经营情况报告.pdf	提取 6×4 区域销售额表格	问“华东区 Q3 销售额和同比” → 1,853.94 万元、-11.2%，带 [1] 引用
双 11 大促复盘摘要.docx	提取 4×4 渠道退款率表格	问“双 11 当天销售额及占比” → 809.78 万元、26.4%
各渠道退款率截图.png	视觉模型识别出 4×4 表格	问“哪个渠道退款率最高” → 小程序 5.57%



文档就绪：正文与表格已提取



文档问答：回答带引用片段



图片截图识别为数据集

九、工程化与稳定性

9.1 安全与可追溯

1. **密钥安全**：API Key 只存后端 `.env`，已被 `.gitignore` 排除；前端不接触密钥；
2. **SQL 安全**：只读连接 + 静态校验 + 白名单 + LIMIT + 超时；
3. **公网保护**：支持访问口令与每分钟限流，防止演示地址被刷；
4. **失败降级**：模型超时 / 报错时自动回退规则版演示模式，保证现场可演示；
5. **异常兜底**：全局异常处理器保证接口始终返回 JSON；
6. **可解释**：SQL 检查器、文档引用、执行耗时全部可见。

9.2 数据源与会话状态

- 按数据源 / 文档缓存对话，切换后回来可继续；
- “新建对话”主动清空当前会话；
- “重置数据源”重新读取原始文件并重建分析表，避免旧数据污染；
- 重置支持示例数据与上传数据，接口为 `POST /api/datasets/{id}/reset`。

9.3 多端交付

- **GitHub 一键环境**：仓库内置 `.devcontainer`，点 Codespaces 徽章即可在云端安装依赖、构建前端并启动 8000 端口；
- **考官一键启动包**：双击 `启动演示.bat`，自动创建 venv、安装依赖（清华镜像）、读取模型 Key、启动服务并打开浏览器；
- **Docker / Render**：提供 `Dockerfile`、`docker-compose.yml`、`render.yaml`，单容器单端口部署；
- **真机模拟**：在独立目录从零安装验证，发现并修复默认 PyPI 卡顿、requirements 缺依赖等问题。

十、测试与评测

10.1 真实模型评测（36,000 行双 11 数据）

问题	结果	耗时
各区域的销售额对比	✅ 正确 SQL + 中文洞察	8.9s
2025 年双 11 当天各小时销售额趋势	✅ 正确日期过滤 + 双峰洞察	12.2s
销售额最低的 3 个品类	✅ 升序 +“最低”洞察	7.8s
各渠道的退款率排名	✅ CASE WHEN 比率计算	9.3s
最近 30 天的销售额趋势	✅ 以数据最大日期为基准	12.5s
华东地区销售额最高的 3 个城市	✅ 自动修复后成功	12.5s

10.2 可视化与交互验证

- **推荐器**：区域对比 → 柱状；品类占比 → 商品图；区域 × 渠道 → 热力图；连续双数值 → 散点（低离散值自动不推荐）；
- **图表修复**：热力图同一单元格聚合去重、关闭动画、标签防重叠；退款率 KPI 改为平均 / 最高 / 最低，不再误显示“合计 100%”；
- **商品图**：灰度图形 + 图像内部占比、4 列布局、窄屏自适应、入场动画、悬停放大、点击填入下钻问题；
- **路由与状态**：切换数据源再返回，消息节点数保持 2 → 2；点“重置数据源”后提示重新读取成功。

10.3 工程与安装验证

- 干净环境安装：43 个 Python 发行包、约 270MB，首次安装约 2 分钟；启动后真实模型、前端页面、示例数据均正常；
- 重置接口：示例数据与上传 CSV 均验证通过；

- 前端 E2E：真实浏览器点击完成“上传 → 提问 → 图表 → 检查器 → 文档问答”，无浏览器报错；
- 演示视频：6 分 06 秒、1920×1080、8fps、配音 + 烧录字幕。

10.4 模型选型评测

模型	单问耗时	结论
qwen3.8-max-0902	30–90s	质量高但现场演示过慢
qwen-plus（采用）	**8–12s**	质量与速度平衡最好
glm-5.2-fast-preview	4–6s	最快，复杂问题质量略降
qwen3.8-flash	12–53s	波动大，不采用

十一、部署与运行

11.1 本地运行

```
powershell -ExecutionPolicy Bypass -File scripts\setup.ps1   # 安装依赖 + 生成演示数据
powershell -ExecutionPolicy Bypass -File scripts\dev.ps1     # 启动前后端
# 访问 http://127.0.0.1:5173（开发）或 http://127.0.0.1:8000（生产单端口）
```

11.2 考官一键启动包

解压后双击 `启动演示.bat`，脚本会自动：

1. 检查 Python；

2. 创建虚拟环境并安装后端依赖（清华镜像优先）；

3. 从 `judge/backend.env` 读取模型 Key（没有则自动演示模式）；

4. 复用已构建的前端 `dist`；

5. 启动 8000 端口并打开浏览器。

11.3 Docker / 云平台

```
docker compose up -d --build
# 访问 http://服务器IP:8000
```

仓库同时提供 `render.yaml`，可在 Render 上一键部署；`APP_ACCESS_CODE` 可设置访问口令，`RATE_LIMIT_PER_MIN` 可限流。

11.4 GitHub Codespaces

仓库内置 `.devcontainer`，点击 README 的 “Open in GitHub Codespaces” 徽章即可：

- 自动安装 Python 依赖、构建前端、启动 8000 端口；
- 未配置 Key 时自动进入演示模式；
- 在仓库 Secrets 中配置 `LLM_API_KEY` 即可使用真实模型。

十二、局限与演进规划

12.1 当前局限

- 以单表分析为主，多表 JOIN 仍需用户明确表关系；
- 准确率依赖模型与数据质量，复杂口径问题需要更多示例；
- 上传限制 30MB，大文件需先抽样；
- 商品图为自绘矢量图形，尚未接入真实商品照片素材；
- 图表推荐以规则引擎为主，复杂业务意图仍需要大模型参与判断；
- 公网部署与多用户权限尚未完善。

12.2 演进路线

1. **语义层与口径配置**：把指标口径固化，减少模型自由发挥；
2. **多表关系与 JOIN**：自动识别表间关系，支持跨表分析；
3. **真实商品图**：支持透明 PNG / SVG 商品素材，自动灰度与内部占比；
4. **图表推荐 2.0**：引入大模型判断业务意图，结合规则生成更准确的推荐理由；
5. **看板与分享**：把分析卡片固定为看板，支持团队协作；
6. **评测体系**：建立 50+ 题的 Text-to-SQL 与可视化评测集，量化准确率与修复率。

十三、团队分工

成员	分工
罗勇添	项目统筹、后端架构、NL2SQL 链路、模型接入与调优
辛嘉炜	前端开发、图表与交互、E2E 测试与演示脚本
林俊宁	文档解析与 RAG、测试数据、技术文档与演示视频
指导老师 林龙键	选题指导、方案评审、比赛材料把关

附录 A：NL2SQL Prompt（节选）

```
# 角色
你是「问数 AskData」的资深数据分析师 & Text-to-SQL 引擎。
任务：把用户问题翻译成 1 条可在 DuckDB 执行的 SELECT，并给出分析意图。

# 环境
- 数据实际时间范围：{DATA_TIME_RANGE}
- 只允许单条 SELECT/WITH，必须包含 LIMIT {MAX_ROWS}

# 数据表结构
{SCHEMA_BLOCK}

# 输出格式（只输出 JSON）
{"intent":"query","plan":"...","sql":"...",
 "chart":{"type":"line|bar|pie|scatter|table","x":"...","y":["..."]},
 "assumptions":[],"clarification":null}

# 规则
1. 只能使用真实存在的表与字段，中文标识符用双引号；
2. 所有输出列使用中文业务别名，chart.x / chart.y 与结果列一致；
3. 时间口径以数据实际范围为准，“上个月/最近 N 天”用 MAX(时间字段) 为基准；
4. 图表类型只是建议，前端会根据数据画像与意图重新推荐；
5. 无法回答时返回 intent=clarify 并给出 2–3 个澄清选项。
```

附录 B：主要 API

方法	路径	说明
POST	/api/datasets/upload	上传 CSV / Excel
POST	/api/datasets/demo	载入示例数据
GET	/api/datasets	数据集列表
POST	/api/datasets/{id}/reset	重置数据源（重新读取原始文件）
POST	/api/chat	自然语言分析
POST	/api/query	检查器执行 SQL
POST	/api/documents/upload	上传 PDF / Word / 图片
POST	/api/documents/{id}/ask	文档 RAG 问答
GET	/api/health	服务与模型状态

本技术文档由项目组编写，截图与数据均来自系统真实运行结果。